0.0 IMPORTS

0.1. Helper Functions

```
In [2]:
    def cramer_v(x, y ):
        #cm = pd.crosstab(x, y ).as_matrix()
        cm = pd.crosstab(x, y ).to_numpy()
        n = cm.sum()
        r, k = cm.shape

    chi2 = stats.chi2_contingency( cm )[0]
    chi2corr = max( 0, chi2 - (k-1)*(r-1)/(n-1) )

    kcorr = k - (k-1)**2/(n-1)
    return np.sqrt( (chi2corr/n) / ( min( kcorr-1, rcorr-1 )))

# Função para ampliar area de edição do jupyter notebook
def jupyter_settings():
    "matplottib inline
    "put.style.use( 'bmh')
    plt.style.use( 'bmh')
    plt.rcParams['figure.figsize'] = [25, 12]
    plt.rcParams['figure.figsize'] = [25, 12]
    plt.rcParams['font.size'] = 24

    display( HTML ('sstyle>-container {width:100% !important; } </style>'))
    pd.options.display.max_columns = Mone
    pd.set_option ('display.expand_frame_repr', False)

    sns.set()

In [3]: jupyter_settings()
```

Populating the interactive namespace from numpy and matplotlib

0.2. Loading data

```
In [4]: # leitura dos dados fornecidos
          df_sales_raw = pd.read_csv('../data/train.csv', low_memory=False)
df_store_raw = pd.read_csv('../data/store.csv', low_memory=False)
          df_raw = pd.merge(df_sales_raw, df_store_raw, how='left', on='Store')
In [5]: # teste de leitura simples
    df_raw.sample()
Out[5]:
               Store DayOfWeek Date Sales Customers Open Promo StateHoliday SchoolHoliday StoreType Assortment CompetitionDistance CompetitionOpenSinceMonth CompetitionOpenSinceYear Promo 2 Promo2SinceWeek
                               3 2014-
08-13 6454
         367540 318
                                                   588 1
                                                                     0
                                                                                    0
                                                                                                 1
                                                                                                            d
                                                                                                                        С
                                                                                                                                       32330.0
                                                                                                                                                                       3.0
                                                                                                                                                                                              2014.0
                                                                                                                                                                                                                           NaN
```

1.0. PASSO 01 - DESCRICAO DOS DADOS

1.1. Rename Columns

1.2. Data Dimensions

```
In [9]: # leitura de colunas/linhas do dataset para dimensionar os dados
print('Number of Rows: {}'.format(dfl.shape[0]))
print('Number of Cols: {}'.format(dfl.shape[1]))

Number of Rows: 1017209
Number of Cols: 18
```

1.3. Data Types

1.0. Data Type

In [10]: df1['date'] = pd.to_datetime(df1['date'])
df1.dtypes
store int64

```
day_of_week
                                            datetime64[ns]
date
sales
                                                         int64
 customers
                                                         int64
 open
                                                          int64
promo
 state holiday
                                                        object
 school holiday
                                                         int64
store_type
assortment
                                                        object
object
competition distance
                                                       float64
competition_distance
competition_open_since_month
competition_open_since_year
promo2
                                                       float64
                                                       float64
                                                       float64
promo2_since_week
promo2_since_year
promo_interval
dtype: object
                                                       float64
                                                        object
1.4. Ckeck NA
```

```
# Verificando colunas com registros vazios
dfl.isna().sum()
In [11]:
               store
Out[11]:
               day_of_week
               date
                                                                             0
               sales
customers
               open
               promo
               state_holiday
school_holiday
store_type
               assortment
               competition_distance
competition_open_since_month
competition_open_since_year
                                                                        2642
                                                                    323348
               promo2
                promo2 since week
                                                                     508031
               promo2_since_week
promo2_since_year
promo_interval
dtype: int64
                                                                     508031
```

1.5. Fillout NA

```
In [12]:
# competition distance --> 2642 registros vazios
# Verificando qual a maior distancia de um concorrente -> 75860.0
# SOLUÇÃO para popular registros vazios-> Vou aplicar uma distancia maxima = 200000.0 para os registros NAN desta coluna
dfl['competition_distance'] = dfl['competition_distance'].apply( lambda x: 200000.0 if math.isnan(x) else x )
                          #promo2 since week --> 508031 registros vazios
                           ##Promoz_since_week --> > soos31 registros vazios | Feystros vazio
                           #promo2_since_year --> 508031 registros vazios
# SOLUÇÃO para popular registros vazios-> APLICAR A DATA (ano) DE VENDA NESTE CAMPO, PARA DEPOIS TESTAR USANDO CRISP E AVALIAR O ALGORITMO
dfl['promo2_since_year'] = dfl.apply( lambda x: x['date'].year if math.isnan( x['promo2_since_year']) else x['promo2_since_year'], axis=1)
                          #promo_interval --> 508031 registros vazios
#criando um mapa de mês
month_map = {1: 'Jan', 2: 'Fev', 3: 'Mar', 4: 'Apr', 5: 'May', 6: 'Jun', 7: 'Jul', 8: 'Aug', 9: 'Sep', 10: 'Oct', 11: 'Nov', 12: 'Dec'}
                           # Colocando 0 nos registros que possui a coluna promo_interval = 0 df1['promo_interval'].fillna( 0, inplace=True )
                          # Criei uma coluna month_map onde será gravado o mes da coluna 'date' do registro, já convertido de acordo com a biblioteca criada df1['month_map'] = df1['date'].dt.month_map ( month_map )
                          # Criei uma nova coluna que vai registrar l para quem tem promoção no mes de venda e θ data de venda fora da promoção dfl['is_promo'] = dfl[['promo_interval', 'month_map']].apply( lambda x: θ if x['promo_interval'] == θ else l if x['month_map'] in x['promo_interval'].split( ',' ) else θ, axis=l )
                                releitura para conferir se ainda temos registros vazios
                          dfl.isna().sum()
                         store
 Out[13]:
                         day_of_week
date
                         sales
                         customers
                         open
                         state_holiday
school_holiday
                         store_type
assortment
competition_distance
                         competition_open_since_month
competition_open_since_year
                         promo2
                         promo2_since_week
                         promo2_since_year
promo_interval
                         month map
                         is_promo
dtype: int64
```

1.6. Change types

```
In [14]: # competition
dfl['competition_open_since_month'] = dfl['competition_open_since_month'].astype(int)
dfl['competition_open_since_year'] = dfl['competition_open_since_year'].astype(int)

# promo2
dfl['promo2_since_week'] = dfl['promo2_since_week'].astype(int)
dfl['promo2_since_year'] = dfl['promo2_since_year'].astype(int)
```

In [15]: # releitura dos tipos de dados para conferencia dfl.dtypes

 Out[15]:
 store
 int64

 day_of_week
 int64

 date
 dateime64[ns]

 sales
 int64

 customers
 int64

 open
 int64

```
int64
 state holiday
                                                                                                    object
 school_holiday
store_type
assortment
competition_distance
                                                                                                      int64
                                                                                                 object
object
float64
competition_open_since_month
competition_open_since_year
promo2_since_week
promo2_since_week
                                                                                                      int64
                                                                                                      int64
                                                                                                      int64
int64
promo2_since_week
promo2_since_year
promo_interval
month_map
is_promo
dtype: object
                                                                                                      int64
                                                                                                   object
object
int64
```

1.7. Descriptive Statistical

```
In [16]: # Criando dataframes de acordo com o typo da coluna
num_attributes = dfl.select_dtypes( include=['int64', 'int32', 'float64'])
cat_attributes = dfl.select_dtypes( exclude=['int64', 'int32', 'float64', 'datetime64[ns]'])
```

1.7.1 Numerical Attributes

Out[17]:

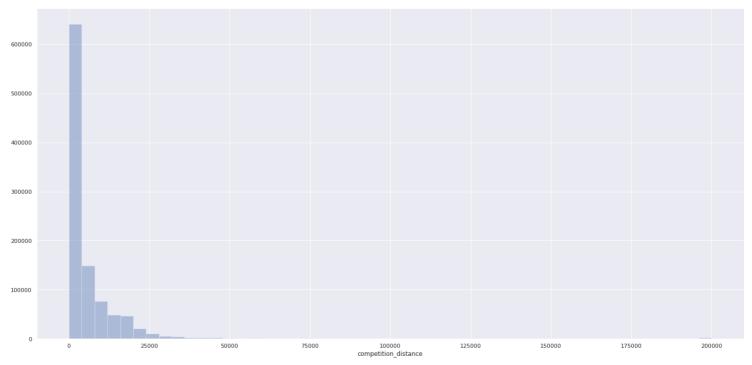
```
In [17]: # Dividindo o datafame em dados numéricos e categóricos # Realizar calculos basicos para cada coluna, para ter uma noção dos dados
                     ttl = pd.DataFrame( num_attributes.apply( np.mean ) ).T
ct2 = pd.DataFrame( num_attributes.apply( np.median ) ).T
                      #Dispersion
                                                  std. min. max. range, skew, kurtosis
                     #Dispersion - std, min, max, range, skew, kurrosis
d1 = pd.DataFrame( num_attributes.apply( np.std ) ).T
d2 = pd.DataFrame( num_attributes.apply( min ) ).T
d3 = pd.DataFrame( num_attributes.apply( max ) ).T
d4 = pd.DataFrame( num_attributes.apply( lambda x: x.max() - x.min() ) ).T
d5 = pd.DataFrame( num_attributes.apply( lambda x: x.skew() ) ).T
d6 = pd.DataFrame( num_attributes.apply( lambda x: x.kurtosis() ) ).T
                     # Concatenate
                     m = pd.concat( [d2, d3, d4, ct1, ct2, d1, d5, d6] ).T.reset_index()
                     m - parconcex()
#Rename columns
m.columns = ['attributes', 'min', 'max', 'range', 'mean', 'median', 'std', 'skew', 'kurtosis']
```

	attributes	min	max	range	mean	median	std	skew	kurtosis
0	store	1.0	1115.0	1114.0	558.429727	558.0	321.908493	-0.000955	-1.200524
1	day_of_week	1.0	7.0	6.0	3.998341	4.0	1.997390	0.001593	-1.246873
2	sales	0.0	41551.0	41551.0	5773.818972	5744.0	3849.924283	0.641460	1.778375
3	customers	0.0	7388.0	7388.0	633.145946	609.0	464.411506	1.598650	7.091773
4	open	0.0	1.0	1.0	0.830107	1.0	0.375539	-1.758045	1.090723
5	promo	0.0	1.0	1.0	0.381515	0.0	0.485758	0.487838	-1.762018
6	school_holiday	0.0	1.0	1.0	0.178647	0.0	0.383056	1.677842	0.815154
7	competition_distance	20.0	200000.0	199980.0	5935.442677	2330.0	12547.646829	10.242344	147.789712
8	competition_open_since_month	1.0	12.0	11.0	6.786849	7.0	3.311085	-0.042076	-1.232607
9	competition_open_since_year	1900.0	2015.0	115.0	2010.324840	2012.0	5.515591	-7.235657	124.071304
10	promo2	0.0	1.0	1.0	0.500564	1.0	0.500000	-0.002255	-1.999999
11	promo2_since_week	1.0	52.0	51.0	23.619033	22.0	14.310057	0.178723	-1.184046
12	promo2_since_year	2009.0	2015.0	6.0	2012.793297	2013.0	1.662657	-0.784436	-0.210075
13	is_promo	0.0	1.0	1.0	0.155231	0.0	0.362124	1.904152	1.625796

```
In [18]: sns.distplot( dfl['competition distance'], kde=False )
```

/home/leandro/.local/lib/python3.9/site-packages/seaborn/distributions.py:2619: FutureWarning: `distplot` is a deprecated function and will be removed in a future version. Please a dapt your code to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).
warnings.warn(msg, FutureWarning)
<AxesSubplot:xlabel='competition_distance'>

Out [181:

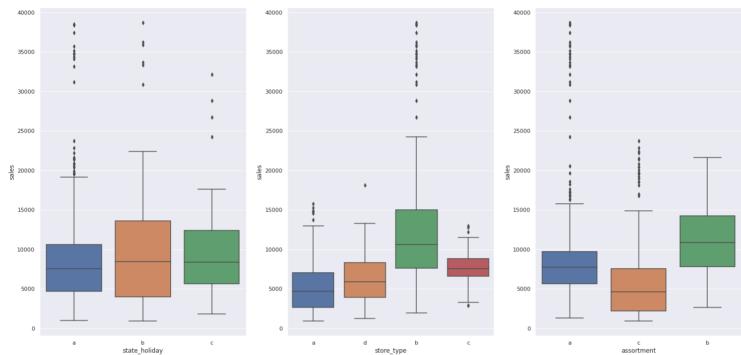


1.7.2 Caterigal Attributes

promo_interval

```
In [19]: cat_attributes.apply( lambda x: x.unique().shape[0] )
Out[19]: state_holiday
          store_type
assortment
```





2.0. PASSO 02 - FEATURE ENGINEETING

In [21]: # fazer uma cópia do dataset ao ir para um próximo passo ou seção, somente para manter os dados , caso seja necessário recomeçar df2 = df1.copy()

2.1. Mapa Mental de Hipóteses

Feito Feature Engineering para criar listas de hipóteses e validar dados $Image('.../img/DAILY_STORE_SALES.png')$ Out[22]: Perto Hospital made for free at coggle.it Urhano Frequencia compra < Bairro LOCALIZAÇÃO Profissão 4 Perto Escola Salario 4 **CLIENTES** Volume de Compra Rural Numero de filhos Competidores Centro Idade Tamanho LOJAS Familia 4 DAILY STORE SALES Número de funcionários Estoque Promoção Hora Variedade (sortimento) Preço Saldão, sales Marketing < Dia **PRODUTOS** Feriados Exposição Loja < **TEMPORAL** Quantidade em estoque « Semana do Ano Ano Final de semana

2.1. Criação das Hipóteses

2.1.1. Hipóteses Loja

- 1. Lojas com número maior de funcionários deveriam vender mais.
- 2. Lojas com maior capacidade de estoque deveriam vender mais.
- 3. Lojas com maior porte deveriam vender mais.
- 4. Lojas com maior sortimentos deveriam vender mais.
- 5. Lojas com competidores mais próximos deveriam vender menos.
- 6. Lojas com competidores a mais tempo deveriam vender mais

2.1.2. Hipóteses Produto

- 1. Lojas que investem mais em Marketing deveriam vender mais.
- 2. Loias com major exposição de produtos deveriam vender mais.
- 3. Lojas com produtos com preço menor deveriam vender mais.
- 4. Lojas com promoções mais agressivas (desconto maiores), deveriam vender mais
- 5. Lojas com promoções ativas por mais tempo deveriam vender mais.
- 6. Lojas com mais dias de promoção deveriam vender mais
- 7. Lojas com mais promoções consecutivas deveriam vender mais.

2.1.3. Hipóteses Tempo

- 1. Lojas abertas durante o feriado de Natal deveriam vender mais.
- 2. Loias deveriam vender mais ao loigo dos anos.
- 3. Lojas deveriam vender mais no segundo semestre do ano.
- 4. Lojas deveriam vender mais depois do dia 10 de cada mês.
- 5. Lojas deveriam vender menos aos finais de semana.
- 6. Lojas deveriam vender menos durante os feriados escolares

2.2. Lista final de Hipóteses

- 1. Lojas com maior sortimentos deveriam vender mais.
- 2. Lojas com competidores mais próximos deveriam vender menos.
- 3. Lojas com competidores a mais tempo deveriam vender mais.
- 4. Lojas com promoções ativas por mais tempo deveriam vender mais.
- 5. Lojas com mais dias de promoção deveriam vender mais
- 6. Lojas com mais promoções consecutivas deveriam vender mais.
- 7. Lojas abertas durante o feriado de Natal deveriam vender mais.
- 8. Lojas deveriam vender mais ao lojgo dos anos.
- 9. Lojas deveriam vender mais no segundo semestre do ano.
- 10. Lojas deveriam vender mais depois do dia 10 de cada mês.
- 11. Lojas deveriam vender menos aos finais de semana.
- 12. Lojas deveriam vender menos durante os feriados escolares

1

1

С

basic

regular day

open

state holiday

store_type

assortment

1

regular day

1

а

basic

1

basic

regular day

1

2.2. Feature Engineering

```
In [23]: # Criando novas features utilizando os dados do dataset
              df2['year'] = df2['date'].dt.year
             # Month
df2['month'] = df2['date'].dt.month
              df2['day'] = df2['date'].dt.day
              # Week of Year
              ###df2['week_of_year'] = df2['date'].dt.weekofyear
df2['week_of_year'] = df2['date'].dt.isocalendar().week
              df2['year week'] = df2['date'].dt.strftime('%Y-%W')
             #competition since
df2['competition_since'] = df2.apply(lambda x: datetime.datetime(year=x['competition_open_since_year'], month=x['competition_open_since_month'], day=1), axis=1)
df2['competition_time_month'] = (( df2['date'] - df2['competition_since'])/30 ).apply(lambda x: x.days).astype(int)
In [24]:
              # Fromo Since | = df2['promo2_since_year'].astype(str) + '-' + df2['promo2_since_week'].astype(str) df2['promo_since'] = df2['promo_since'].apply(lambda x: datetime.datetime.strptime( x + '-1', '%Y-%W-%w') - datetime.timedelta( days=7)) df2['promo_time_week'] = ((df2['date'] - df2['promo_since'])/7 ).apply(lambda x: x.days).astype(int)
              # ASSORTMENT
df2['assortment'] = df2['assortment'].apply( lambda x: 'basic' if x == 'a' else 'extra' if x == 'b' else 'extended')
             # State holiday df2['state_holiday'] = df2['state_holiday'].apply( lambda x: 'public_holiday' if x == 'a' else 'easter_holiday' if x == 'b' else 'christmas' if x == 'c' else 'regular_day' )
In [28]: df2.head().T
Out[281:
                                                                5
                                                                                      5
                                                                                                                                   5
                                                                                                            5
                                                                                                                                                         5
                                         date 2015-07-31 00:00:00 2015-07-31 00:00:00 2015-07-31 00:00:00 2015-07-31 00:00:00 2015-07-31 00:00:00
                                                              5263 6064 8314
                                   customers
                                                                555
                                                                                     625
                                                                                                           821
                                                                                                                                1498
                                                                                                                                                       559
```

1

regular day

extended

basic

	0	1	2	3	4
competition_distance	1270.0	570.0	14130.0	620.0	29910.0
competition_open_since_month	9	11	12	9	4
competition_open_since_year	2008	2007	2006	2009	2015
promo2	0	1	1	0	0
promo2_since_week	31	13	14	31	31
promo2_since_year	2015	2010	2011	2015	2015
promo_interval	0	Jan,Apr,Jul,Oct	Jan,Apr,Jul,Oct	0	0
month_map	Jul	Jul	Jul	Jul	Jul
is_promo	0	1	1	0	0
year	2015	2015	2015	2015	2015
month	7	7	7	7	7
day	31	31	31	31	31
week_of_year	31	31	31	31	31
year_week	2015-30	2015-30	2015-30	2015-30	2015-30
competition_since	2008-09-01 00:00:00	2007-11-01 00:00:00	2006-12-01 00:00:00	2009-09-01 00:00:00	2015-04-01 00:00:00
competition_time_month	84	94	105	71	4
promo_since	2015-07-27 00:00:00	2010-03-22 00:00:00	2011-03-28 00:00:00	2015-07-27 00:00:00	2015-07-27 00:00:00
promo time week	0	279	226	0	0

3.0. PASSO 03 - FILTRAGEM DE VARIÁVEIS

In [29]: df3 = df2.copy()

3.1. Filtragem das Linhas

criando novo dataset com lojas abertas e com vendas df3 = df3[(df3['open'] != 0) & (df3['sales'] > 0)]

3.2. Seleção das Colunas

```
# removendo colunas desnecessárias para analise de dados e deixar o processamento mais rapido
cols_drop = ['customers', 'open', 'promo_interval', 'month_map']
df3 = df3.drop(cols_drop, axis=1)
```

In [32]: df3.columns

4.0. PASSO 04 - ANALISE EXPLORATORIA DOS DADOS (EDA)

In [33]: #Etapa para medir impacto das variáveis, quantificar seu impacto, validar hipóteses de negócios e gerar INSIGHTS df4 = df3.copy()

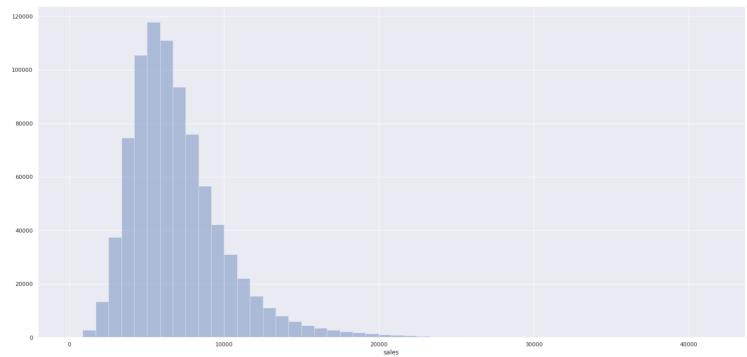
4.1. Analise Univariada

4.1.1. Response Variable

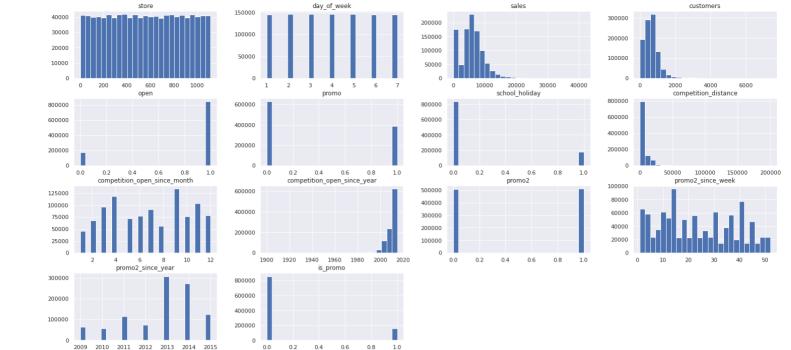
```
In [34]: #plt.figure( figsize=(220,112))
    sns.distplot( df4['sales'], kde=False )
```

/home/leandro/.local/lib/python3.9/site-packages/seaborn/distributions.py:2619: FutureWarning: `distplot` is a deprecated function and will be removed in a future version. Please a dapt your code to use either `displot` (a figure-level function with similar flexibility) or `histplot` (an axes-level function for histograms).
warnings.warn(msg, FutureWarning)
<AxesSubplot:xlabel='sales'>

Out[34]:



4.1.2. Numerical Variable



4.1.3. Categorical Variable

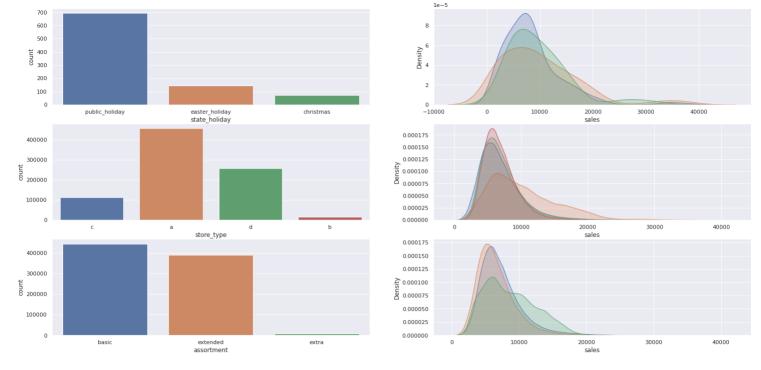
df4['state_holiday'].drop_duplicates()

In [36]:

Out[39]:

```
regular_day
public_holiday
easter_holiday
christmas
                      0
63559
Out[36]:
                      241126
                      Name: state_holiday, dtype: object
In [37]: df4['store_type'].drop_duplicates()
Out[37]:
                      12
                       Name: store_type, dtype: object
In [38]: df4['assortment'].drop duplicates()
                      0
                                            basic
Out[38]:
                                      extended
                      258 extra
Name: assortment, dtype: object
In [39]: # state holiday
                        #criando um grafico com todos os feriados
                       plt.subplot( 3, 2, 1 )
a = df4[df4['state_holiday'] != 'regular_day']
sns.countplot( a['state_holiday'])
                       #Criando um grafico com as colunas sobrepostas -> shade=True
plt.subplot( 3, 2, 2 )
sns.kdeplot( df4[df4['state_holiday'] == 'public_holiday']['sales'], label='public_holiday', shade=True )
sns.kdeplot( df4[df4['state_holiday'] == 'easter_holiday']['sales'], label='easter_holiday', shade=True )
sns.kdeplot( df4[df4['state_holiday'] == 'christmas']['sales'], label='christmas', shade=True )
                       # store_type
plt.subplot( 3, 2, 3 )
sns.countplot( df4['store_type'])
                        plt.subplot( 3
                       pit.subplot( 3, 2, 4)
sns.kdeplot( df4[df4['store_type'] == 'a']['sales'], label='a', shade=True
sns.kdeplot( df4[df4['store_type'] == 'b']['sales'], label='b', shade=True
sns.kdeplot( df4[df4['store_type'] == 'c']['sales'], label='c', shade=True
sns.kdeplot( df4[df4['store_type'] == 'd']['sales'], label='d', shade=True
                       plt.subplot( 3, 2, 5 )
sns.countplot( df4['assortment'])
                        plt.subplot( 3
                       sns.kdeplot( df4[df4['assortment'] == 'extended']['sales'], label='extended', shade=True )
sns.kdeplot( df4[df4['assortment'] == 'basic']['sales'], label='basic', shade=True )
sns.kdeplot( df4[df4['assortment'] == 'extra']['sales'], label='extra', shade=True )
                      /home/leandro/.local/lib/python3.9/site-packages/seaborn/_decorators.py:36: FutureWarning: Pass the following variable as a keyword arg: x. From version 0.12, the only valid positional argument will be 'data', and passing other arguments without an explicit keyword will result in an error or misinterpretation.
                          warnings.warn(
                     warnings.warn(
/home/leandro/.local/lib/python3.9/site-packages/seaborn/_decorators.py:36: FutureWarning: Pass the following variable as a keyword arg: x. From version 0.12, the only valid positi
onal argument will be 'data', and passing other arguments without an explicit keyword will result in an error or misinterpretation.
warnings.warn(
/home/leandro/.local/lib/python3.9/site-packages/seaborn/_decorators.py:36: FutureWarning: Pass the following variable as a keyword arg: x. From version 0.12, the only valid positi
onal argument will be 'data', and passing other arguments without an explicit keyword will result in an error or misinterpretation.
```

warnings.warn(
<AxesSubplot:xlabel='sales', ylabel='Density'>



4.2. Analise Bivariada

S 1.5

0.5

0.0

H1. Lojas com maior sortimentos deveriam vender mais.

basic

FALSA Lojas cim MAIOR SORTIMENTO vendem MENOS

```
In [40]: #sortimento + vendas --> agrupa por sortimento
aux1 = df4[['assortment', 'sales']].groupby('assortment').sum().reset_index()
sns.barplot(x='assortment', y='sales', data=aux1);

#semana do ano + sortimento + vendas --> agrupa por semana di ano + sortimento
aux2 = df4[['year_week', 'assortment', 'sales']].groupby(['year_week', 'assortment']).sum().reset_index()
aux2.pivot( index='year_week', columns='assortment', values='sales').plot()

# verificando somente o sortimento extra
aux3 = aux2[aux2['assortment'] == 'extra']
aux3.pivot( index='year_week', columns='assortment', values='sales').plot()

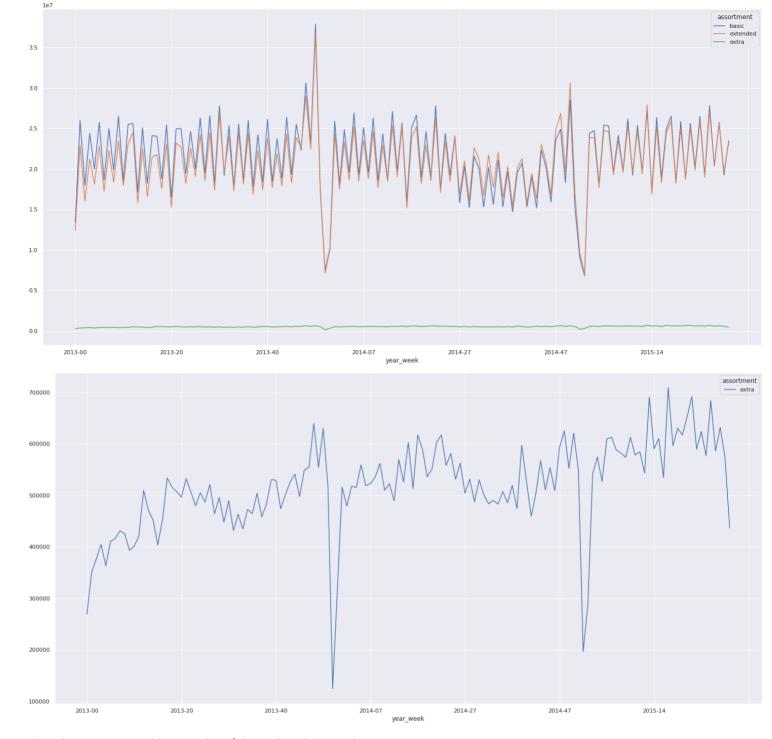
Out[40]: <a href="#"><a href="#">AxesSubplot:xlabel='year_week'></a>

1e9
30

25
```

extended assortment

extra



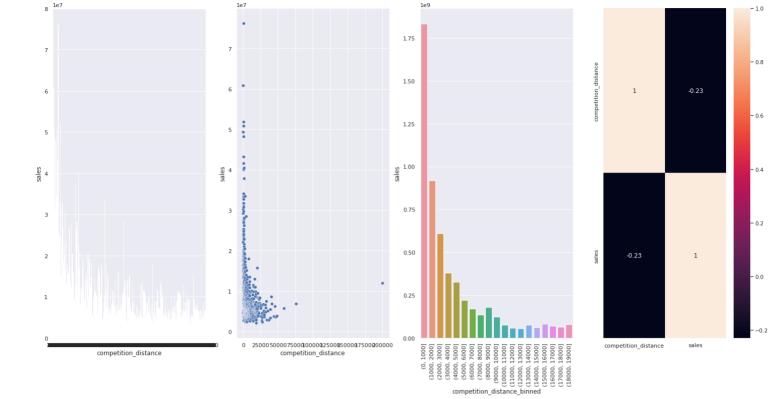
H2. Lojas com competidores mais próximos deveriam vender menos.

Falsa Lojas com COMPETIDORES MAIS PROXIMOS vendem MAIS

```
In [41]: #sortimento + vendas --> agrupa por sortimento
aux1 = df4[['competition_distance', 'sales']].groupby('competition_distance').sum().reset_index()
plt.subplot(1,4,1)
sns.barplot(x='competition_distance', 'y='sales', data=aux1);

aux1 = df4[['competition_distance', 'sales']].groupby('competition_distance').sum().reset_index()
plt.subplot(1,4,2)
sns.scatterplot(x='competition_distance', y='sales', data=aux1);

plt.subplot(1,4,3)
#criando uma lista para agrupar as distancias
# vai de 0 a 20000 e com 1000(grupos) agrupamentos
bins = list(np.arange(0, 20000, 1000))
aux1['competition_distance_binned'] = pd.cut( aux1['competition_distance'], bins=bins)
aux2 = aux1['competition_distance_binned', 'sales']].groupby('competition_distance_binned').sum().reset_index()
sns.barplot(x='competition_distance_binned', 'sales'].groupby('competition_distance_binned').sum().reset_index()
sns.barplot(x='competition_distance_binned', y='sales', data=aux2);
plt.subplot(1,4,4)
sns.heatmap(aux1.corr(method='pearson'), annot=True);
```



H3. Lojas com competidores a mais tempo deveriam vender mais.

Falsa Lojas com COMPETIDORES A MAIS TEMPO vendem MENOS

```
In [42]: pitsubjot(1, 3, 1)

set in pitsubjot(1, 3, 1)

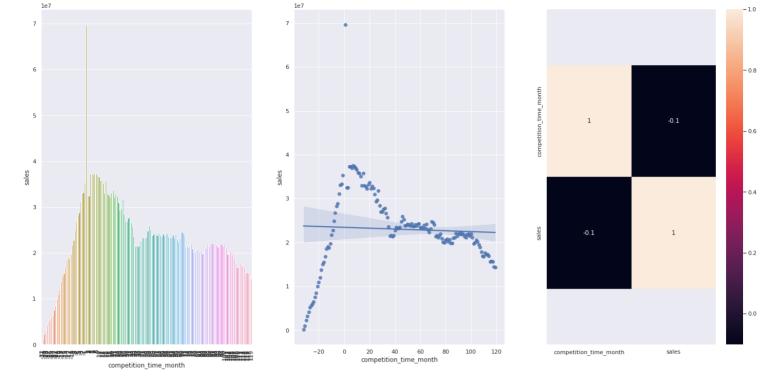
set in pitsubjot(1, 3, 1)

pitsubjot(1, 3, 3)

pitsubjot(1, 3, 1)

pit
```

```
In [43]:
    plt.subplot( 1, 3, 1 )
        aux1 = df4[['competition_time_month', 'sales']].groupby( 'competition_time_month' ).sum().reset_index()
        aux2 = aux1[( aux1['competition_time_month'] < 120 ) & ( aux1['competition_time_month'] != 0 )]
        sns.barplot( x='competition_time_month', y='sales', data=aux2 );
        plt.subplot( 1, 3, 2 )
        sns.regplot( x='competition_time_month', y='sales', data=aux2 );
        plt.subplot( 1, 3, 3 )
        x = sns.heatmap( aux1.corr( method='pearson'), annot=True );
        bottom, top = x.get_ylim()
        x.set_ylim( bottom+0.5, top-0.5);</pre>
```



H4. Lojas com promoções ativas por mais tempo deveriam vender mais.

Falsa Lojas com promoções ativas por mais tempo vendem menos, depois de um certo periodo de promoção

```
In [44]: aux1 = df4[['promo_time_week', 'sales']].groupby('promo_time_week').sum().reset_index()
               grid = GridSpec( 2, 3 )
               \label{eq:policy} $$ plt.subplot(grid[0,0]) $$ aux2 = aux1[aux1['promo_time_week'] > 0 ] $$ \# promo_extendido $$ sns.barplot( x='promo_time_week', y='sales', data=aux2); $$ plt.xticks(rotation=90); $$
               \label{eq:policy} $$ ptt.subplot(grid[1,0]) $$ aux3 = aux1[aux1['promo_time_week'] < 0]  # promo regular $$ sns.barplot( x='promo_time_week', y='sales', data=aux3); $$ ptt.xticks(rotation=90); $$ $$
               plt.subplot(grid[1,1])
sns.regplot( x='promo_time_week', y='sales', data=aux3);
               plt.subplot(grid[:,2])
sns.heatmap(aux1.corr(method='pearson'), annot=True);
                 2.5
                 2.0
              8 1.5
ES
                                                                                                                                                                                                                                                                  -0.029
                 1.0
                                                                                                                 0.5
                  0.5
                                                                                                                 0.0
                                                    promo time week
                                                                                                                                                                                                                                  -0.029
                          promo_time_week
                                                                                                                                                   promo_time_week
                                                    promo_time_week
```

H5. Lojas com mais dias de promoção deveriam vender mais.

Validar no proximo ciclo crisp

H6. Lojas com mais promoções consecutivas deveriam vender mais.

Falsa Lojas com ais promoções consecutivas vendem menos

In [45]: df4[['promo', 'promo2', 'sales']].groupby(['promo', 'promo2']).sum().reset_index()

```
0 0 0 1482612096
1 0 1 1289362241
2 1 0 1628930532
3 1 1 1472275754

In [46]: aux1 = df4[(df4['promo'] == 1 ) & (df4['promo2'] == 1)][['year_week', 'sales']].groupby('year_week').sum().reset_index()
aux2 = df4[(df4['promo'] == 1 ) & (df4['promo2'] == 0 )][['year_week', 'sales']].groupby('year_week').sum().reset_index()
aux2.plot(ax=ax)
ax.legend(labels=['Tradiciona & Extendida'], 'Extendida']);

le7

Tradiciona & Extendida
Extendida
```



H7. Lojas abertas durante o feriado de Natal deveriam vender mais.

Falsa Lojas abertas durante o feriado do Natal vendem menos

Out[45]:

```
In (47) aux = drd(drd(*state_holiday*) != 'regular_day*]

put1 = stephot**[1, 2, 3]

put2 = aux([*state_holiday*, 'sales*]].grouphy('state_holiday*).sum().reset_index()

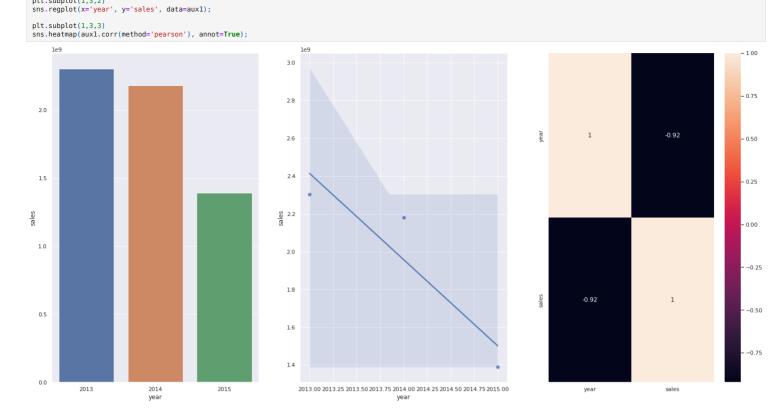
sns.barplot(xw*state_holiday*, 'sales*]].grouphy('yeor*, 'state_holiday*).sum().reset_index()

sns.barplot(xw*state_holiday*, 'sales*]].grouphy('yeor*, 'state_holiday*, 'sales*]].grouphy('yeor*
```

H8. Lojas deveriam vender mais ao lojgo dos anos.

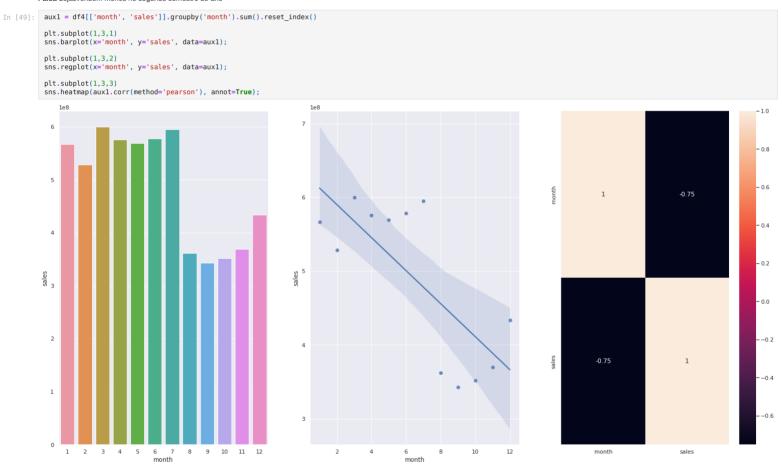
Falsa Lojas vendem menos ao longo dos anos

```
n [48]: aux1 = df4[['year', 'sales']].groupby('year').sum().reset_index()
plt.subplot(1,3,1)
sns.barplot(x='year', y='sales', data=aux1);
```



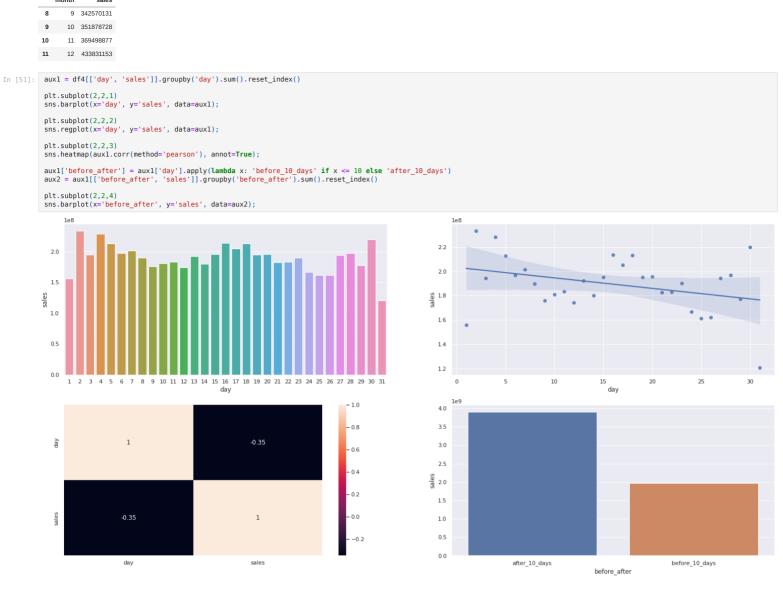
H9. Lojas deveriam vender mais no segundo semestre do ano.

Falsa Lojasvendem menos no segundo semestre do ano



H10. Lojas deveriam vender mais depois do dia 10 de cada mês.

Verdadeira Lojas vendem mais depois do dia 10 de cada mes



H11. Lojas deveriam vender menos aos finais de semana.

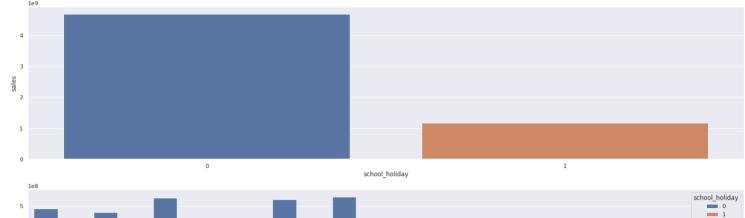
Verdadeira Lojas vendem menos no final de semana

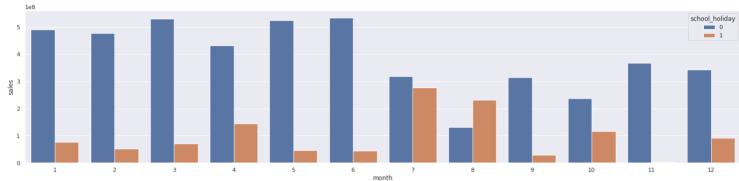
H12. Lojas deveriam vender menos durante os feriados escolares

Verddeiro Lojas vendem menos durante os feriados escolares, exceto os meses de Julho e agosto

```
In [53]: aux1 =df4[['school_holiday', 'sales']].groupby('school_holiday').sum().reset_index()
    plt.subplot(2,1,1)
    sns.barplot(x='school_holiday', y='sales', data=aux1);

aux2 =df4[['month', 'school_holiday', 'sales']].groupby(['month', 'school_holiday']).sum().reset_index()
    plt.subplot(2,1,2)
    sns.barplot(x='month', y='sales', hue='school_holiday', data=aux2);
```





4.2.1. Resumo das Hipoteses

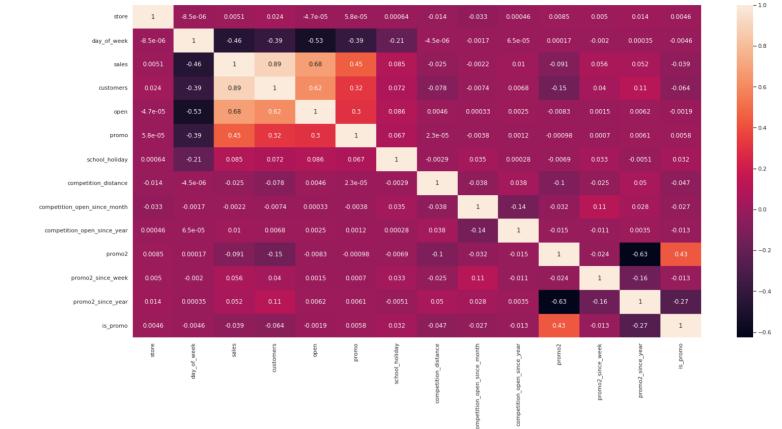
Hipoteses	Conclusao	Relevancia
H1	Falsa	Baixa
H2	Falsa	Media
H3	Falsa	Media
H4	Falsa	Media
H5	-	-
H6	Falsa	Baixa
H7	Falsa	Media
Н8	Falsa	Alta
H9	Falsa	Alta
H10	Verdadeira	Alta
H11	Verdadeira	Alta
H12	Verdadeira	Baixa

4.3. Analise Multivariada

4.3.1. Numerical Attributes

In [55]:	nui	um_attributes.head()													
Out[55]:		store	day_of_week	sales	customers	open	promo	school_holiday	competition_distance	$competition_open_since_month$	competition_open_since_year	promo2	promo2_since_week	promo2_since_year	is_promo
	0	1	5	5263	555	1	1	1	1270.0	9	2008	0	31	2015	0
	1	2	5	6064	625	1	1	1	570.0	11	2007	1	13	2010	1
	2	3	5	8314	821	1	1	1	14130.0	12	2006	1	14	2011	1
	3	4	5	13995	1498	1	1	1	620.0	9	2009	0	31	2015	0
	4	5	5	4822	559	1	1	1	29910.0	4	2015	0	31	2015	0

In [56]: correlation =num_attributes.corr(method='pearson')
sns.heatmap(correlation, annot=True);



4.3.2. Categorical Attributes

state holiday store type assortment promo interval month map

In [57]: cat_attributes.head()

Out[61]: <AxesSubplot:>

Out [571:

```
0
                                                                     0
                                        С
                                                     а
                         0
                                                   a Jan,Apr,Jul,Oct
            1
                                                                                  Jul
                           0
            2
                                       а
                                                     a Jan,Apr,Jul,Oct
                                                                                   Jul
                                 а
            4
                           0
                                                                      0
                                                                                   Jul
In [58]: a = df4.select_dtypes(include='object')
             a.head()
Out[58]:
               state_holiday store_type assortment year_week
                  regular_day
                                       С
                                                 basic
                                                           2015-30
                                  a basic
            1 regular_day
                                                         2015-30
            2 regular_day
                                       а
                                                 basic
                                                           2015-30
            3 regular_day c extended 2015-30
            4 regular day
                                                 basic
                                                          2015-30
                                       а
In [59]: #pd.crosstab( a['state_holiday'], a['store_type']).as_matrix()
In [60]: # only categorical data
             # only tablest atta
a = df4.select_dtypes( include='object')
#cramer_v( a['state_holiday'], a['state_holiday'] )
              # Calculate cramer V
             al = cramer_v(a['state_holiday'], a['state_holiday'])
a2 = cramer_v(a['state_holiday'], a['store_type'])
a3 = cramer_v(a['state_holiday'], a['assortment'])
             a4 = cramer_v( a['store_type'], a['state_holiday'] )
a5 = cramer_v( a['store_type'], a['store_type'] )
a6 = cramer_v( a['store_type'], a['assortment'] )
             a7 = cramer_v( a['assortment'], a['state_holiday'])
a8 = cramer_v( a['assortment'], a['store_type'])
a9 = cramer_v( a['assortment'], a['assortment'])
              #Final dataset
             In [61]: sns.heatmap(d, annot=True )
```

